

김성재 @hippo2coding

LLM 애플리케이션의 **백엔드**를 만듭니다. 에이전트 런타임과 RAG 파이프라인, 그리고 그것이 정말 작동하는지 확인하는 **평가 체계**까지 함께 만듭니다.

↗ github.com/hippo2coding

234

파이널 커밋 (전체의 40%)

5

팀 프로젝트

960

교육 이수 시간

핵심 역량

에이전트 런타임

AGENT RUNTIME • LLM INFRA

- FastAPI 기반 **AgentRunner 런타임 루프**와 요청·응답 계약 스키마를 설계하고, 시스템 프롬프트를 외부 주입형 provider로 분리(SSOT)
- LiteLLM·OpenRouter **프로바이더 어댑터**와 게이트웨이 페일오버, 페르소나 에이전트 등록·라우팅 구현
- Logfire로 **관측성 계층** 구성 - llm.request.prompt.load 구간 span, 토큰 사용량과 캐시 히트 계측

RAG 파이프라인

RETRIEVAL & GROUNDING

- SQL(정형)과 Vector(비정형)를 결합한 **하이브리드 검색**, 검색 실패 시 자동 fallback
- 질문의 의도·대상·경로를 sql / vector / hybrid / clarify로 분류하는 질문 분석기
- 모든 답변에 **출처를 붙이고**, 답변해선 안 되는 질문은 정책으로 차단

평가·데이터셋

EVALUATION ENGINEERING

- 컨텍스트 길이별 **cutoff 생성**과 **사실 생존 판정**, QA 문항 생성·응답, 검증 임계값과 리포트 CLI로 이어지는 장기기억 벤치마크 구축
- 변수 하나만 바꾸는 **통제 실험 설계**와, 체크포인트로 재개 가능한 생성 엔진
- 모델 후보 비교 리포트 작성 (DeepSeek V4 Flash vs Gemma 4 31B)

DearMate


[↗ Repo](#)

AI 컴패니언 앱 · 멀티서비스 모노레포 · 파이널 프로젝트

2026.06 - 08 팀 4인 234 / 580 커밋 (40%) · 2위 기여자

React Native(Expo) 앱, Python Agent Backend, 독립 배포되는 A2A(Google ADK) 에이전트, LiteLLM 게이트웨이가 각각의 경계를 갖는 모노레포입니다. 저는 **에이전트가 실제로 돌아가는** 충을 맡았습니다 — 런타임과 프로바이더, 그리고 그 품질을 재는 평가 파이프라인. 과정 유료중에 **Project : 지훈**으로 등재된 최종 프로젝트입니다.

담당: A2A 에이전트 · Agent Backend(런타임·계약·관측성) · LLM 게이트웨이 · 시스템 프롬프트 · 장기기억 평가




에이전트 · 인프라


- AgentRunner 런타임 루프, LLM 요청·응답 계약 스키마, FastAPI 부트스트랩과 라우터·관측성 배선
- 페르소나 에이전트를 독립 실행 ADK 런타임으로 분리하고, 게이트웨이 파일오버와 Supabase 기반 페르소나 provider를 연결
- 구독 카탈로그 API와 정책·구독 관리 콘솔까지 운영 기능으로 확장

장기 기억 평가 — 컴패니언이 "기억한다"를 측정 가능하게

- 긴 시간축의 관계 서사를 담은 한국어 대화 데이터셋 생성 파이프라인 — 대화 5건 × 15만 토큰 규모, 목표 토큰을 20K 파일럿에서 **400K 본 생성**으로 확장
- 길이별 **cutoff 생성**과 **사실 생존 판정**, QA 문항 생성·응답, 검증 리포트 CLI로 "기억이 남았는지"를 수치로 판정
- 배경·제약·시드·시나리오를 고정하고 성격 유형 변수만 바꾼 **통제 비교 설계**. 경험 원장으로 반복 서술을 막고, 같은 날 상태 충돌은 생성 시점에 반려
- 완료 기준을 파일 크기가 아니라 **JSONL·사실 원장·매니페스트 검증 통과**로 정의하고, 팀원이 독립 실행하도록 portable 번들로 인계



제품 기획 — 페르소나 챗봇을 IP 성장의 핵심 수단으로 정의한 팀 기획 산출물 (선행 연구 4건 인용)



커밋 수치는 팀 작업 저장소를 전 브랜치 기준으로 집계한 값입니다. 공개 저장소에는 통합 시점까지의 스냅샷(421커밋)만 올라가 있어, 기능 브랜치에 남은 작업은 그곳에서 보이지 않습니다.

2026.05 - 06 팀 4인 (두 차수 동일 팀)

여러 공식 페이지와 PDF에 흩어진 KAIST 학과 정보를, **출처와 함께** 답하는 챗봇. 두 차수에 걸쳐 검색 파이프라인을 **운영 가능한 웹서비스**로 키웠습니다.



담당: RAG 파이프라인 설계·구현 (질문 분석 · 하이브리드 검색) 및 서비스 백엔드 연동

3차 - 하이브리드 RAG 파이프라인

- SQL(정형) + Vector(비정형) 검색을 결합하고, 검색 실패나 결과 부족 시 자동 fallback
- 질문 의도·학과·검색 route를 분류하는 질문 분석기와, 애매한 질문용 예시 유사도 매칭
- 개인별 합격 가능성처럼 답변해선 안 되는 질문을 정책적으로 차단

4차 - Django 정식 서비스로 확장

- 인증, 대화 세션, 답변 피드백, 게시판·문의, 관리자 통계까지 구현
- 수집 범위를 AI 관련 4개 학과에서 **3개 단과대학 · 15개 학과·대학원**으로 확대 — 교과목 908 · 교수/연구진 607 · 세미나 439 · 입학/장학 138, 총 **2,092건** 적재
- End-to-End 테스트 9건 전 항목 통과 (라우팅, 인증, DB 연동, 예외 처리)



관리자 - 수집 데이터 2,092건의 구성과 단과대학별 비중

채팅 - 답변마다 근거 문서를 출처 카드와 유사도 점수로 제시

Python

LangChain

OpenAI API

Chroma

MySQL

Django

Streamlit

JavaScript

화면 이미지의 번호 마커는 팀에서 작성한 화면설계서 표기입니다.

첫 프로젝트에서는 커밋을 하나도 남기지 못했습니다. 협업 방식이 서툴렀고, 맡은 일도 스크립트 단위였습니다. 여섯 달 뒤 파이널에서는 580개 커밋 중 **234개**를 남겼습니다. 그 사이를 채운 두 프로젝트입니다.

- 2026.04

Netflix 고객 이탈 예측 ↗

5개 모델을 비교해 CatBoost를 최종 선정 (F1 0.994 · ROC-AUC 0.9999). SHAP으로 이탈에 영향이 큰 피처를 해석하고, Accuracy 대신 Recall·F1 중심으로 평가 기준을 잡았습니다.

담당 머신러닝 모델 개발 및 성능 평가 · 팀 5인
- 2026.03

주차장 검색 & 지역 수급 분석 ↗

공공데이터의 자동차 등록 대수와 주차 면수를 비교해 지역별 수급 불균형을 시각화하고, 리뷰 텍스트 키워드를 정량 데이터와 결합한 혼잡도 지수를 만들었습니다.

담당 데이터 수집·전처리, 자동차 등록 데이터 가공 · 팀 5인

기술 스택

LANGUAGE

Python

TypeScript

JavaScript

SQL

LLM · AGENT

Google ADK / A2A

LangChain

LiteLLM

OpenAI API

OpenRouter

RAG

Chroma

BACKEND

FastAPI

Django

Pydantic AI

Streamlit

DATA · ML

Pandas

Scikit-learn

CatBoost

XGBoost

LightGBM

SHAP

INFRA · OPS

Supabase

PostgreSQL

MySQL

SurrealDB

Docker

Logfire

Git

교육 이수

과정	SK네트웍스 Family AI 캠프 28기 — SK네트웍스 · en·core
분야	인공지능 모델링 · LLM 기반 AI SW/서비스 개발
기간	2026.02.26 – 2026.08.21 · 960시간
최종 프로젝트	LLM 활용 인공지능 인플루언서 만들기 — Project : 지훈 · 백엔드 개발, AI 모델 개발, DB 및 시스템 설계
인증	고용노동부 K-Digital Training 수료 (2026.08.21)

다섯 프로젝트 모두 2026년 2월 26일부터 8월 21일까지 진행된 SK Networks Family AICAMP 28기 과정에서 수행한 팀 프로젝트입니다. 커밋 수치는 저장소 이력을 직접 집계한 값입니다.